

Table des matières

1	Introduction	1
2	Objectif général du projet	1
3	Problématique	2
4	Solution proposée	2
4.1	Module de collecte des données (Web Crawling)	3
4.2	Module de stockage des données	4
4.3	Module d'analyse de graphe	4
4.4	Détection de fermes de liens	4
4.5	Analyse comportementale et Bot Score	4
4.6	Préparation pour l'Intelligence Artificielle	5
4.7	Prétraitement et nettoyage des données textuelles	6
4.8	Construction du Dataset Final et Pipeline d'Exportation	6
4.9	Pipeline d'analyse avancée par Intelligence Artificielle	8
4.9.1	Préparation et organisation des données	8
4.9.2	Augmentation des données	8
4.9.3	Séparation des données et sélection des hyperparamètres	9
4.9.4	Entraînement des modèles de Machine Learning	9
4.9.5	Intégration du Deep Learning avec BERT	9
4.9.6	Analyse de similarité sémantique	9
4.9.7	Comparaison des performances	9
4.9.8	Analyse de polarisation (Stance Analysis)	10
4.9.9	Analyse stylométrique	10
4.10	Système de Scoring Unifié et Classification des Domaines Suspects	11
4.11	Développement du Dashboard Interactif de Cyber Threat Intelligence	15
4.11.1	1. Page Overview — Vue Globale des Menaces	16
4.11.2	2. Page Domains — Analyse détaillée des domaines	18
4.11.3	3. Page ML Engine — Analyse du modèle	21
4.11.4	4. Page Network — Analyse des relations	23
4.11.5	5. Page Pipeline — Vue globale du pipeline CTI	25
5	Conclusion Générale	27

1. Introduction

Avec l'évolution rapide des technologies numériques et la démocratisation de l'accès à Internet, le web est devenu aujourd'hui la principale source d'information pour les individus, les entreprises, les gouvernements et les organisations à travers le monde. Chaque seconde, des millions de contenus sont publiés, partagés et consultés sur différentes plateformes numériques telles que les sites d'actualités, les blogs, les forums et les réseaux sociaux.

Cette transformation digitale a profondément modifié notre manière de communiquer, de nous informer et de prendre des décisions. Cependant, cette ouverture massive de l'information s'accompagne également de nouveaux défis majeurs liés à la sécurité numérique et à la fiabilité des contenus diffusés.

Parmi les menaces les plus importantes figurent :

- la propagation rapide de fausses informations ;
- la manipulation de l'opinion publique à travers des campagnes coordonnées ;
- la diffusion de contenus générés artificiellement ;
- la polarisation idéologique ;
- l'utilisation de bots automatisés pour amplifier artificiellement certains messages ;
- les stratégies de désinformation à grande échelle.

Ces menaces représentent aujourd'hui un enjeu critique dans plusieurs domaines, notamment la cybersécurité, la politique, l'économie et la confiance sociale. Face à cette problématique, il devient indispensable de développer des solutions intelligentes capables de détecter automatiquement ces comportements suspects. C'est dans ce contexte que s'inscrit notre projet.

2. Objectif général du projet

L'objectif principal de ce projet est de concevoir et développer une plateforme intelligente de Cyber Threat Intelligence basée sur le Web Mining et l'Intelligence Artificielle.

Cette plateforme doit permettre de :

- collecter automatiquement des données depuis plusieurs sources web ;
- stocker et organiser ces données dans une architecture adaptée ;
- analyser les relations entre les pages web ;
- détecter des comportements suspects ;
- identifier des activités automatisées ;
- analyser le contenu textuel avec des modèles d'intelligence artificielle ;

- produire des scores de menace ;
- visualiser les résultats dans un dashboard interactif.

L'idée principale est de transformer des données web brutes en information exploitable pour la prise de décision.

3. Problématique

Le principal problème auquel nous faisons face est que les campagnes de désinformation modernes ne reposent plus uniquement sur du contenu faux. Elles combinent plusieurs dimensions :

Dimension structurelle

Des groupes de sites peuvent être interconnectés artificiellement pour augmenter leur crédibilité ou améliorer leur visibilité. Par exemple, plusieurs sites se citent mutuellement afin de créer une illusion de fiabilité.

Dimension comportementale

Des robots logiciels (*bots*) peuvent publier, partager ou consulter du contenu de manière automatique afin d'influencer artificiellement des statistiques ou des tendances. Par exemple, 1 000 visites générées automatiquement pour faire croire qu'un article devient viral.

Dimension sémantique

Le contenu lui-même peut être manipulé. Un article peut sembler légitime mais contenir des biais idéologiques, des formulations trompeuses ou des affirmations fausses.

Le défi principal est donc de détecter simultanément ces trois dimensions.

4. Solution proposée

L'objectif principal était la conception et l'implémentation d'une pipeline complète d'analyse de désinformation web. Cette architecture permet de collecter automatiquement des données web à grande échelle, de les stocker dans différentes bases spécialisées, d'analyser les relations entre les pages web, de détecter des comportements suspects et de préparer un dataset exploitable pour des modèles d'intelligence artificielle.

L'architecture globale du système repose sur une approche modulaire présentée dans la figure suivante.




FIGURE 1 – Schéma du pipeline de traitement des données

4.1 Module de collecte des données (Web Crawling)

La première étape du projet consiste à collecter automatiquement les données depuis plusieurs sources d'information. Les sites ont été organisés en plusieurs catégories afin d'obtenir un dataset varié et représentatif :

- **Sources fiables** : Le Monde, BBC, Reuters, France24, DW.
- **Sources internationales** : CNN, AP News.
- **Sources controversées** : RT, Sputnik.
- **Sources arabes** : Al Jazeera.

L'objectif principal était de construire un dataset multilingue, multi-source, équilibré et représentatif de différents biais médiatiques.

Cette étape repose sur un système de web crawling intelligent capable de :

- visiter automatiquement les sites web ;
- parcourir les liens internes et externes ;
- télécharger le contenu des pages ;
- extraire le texte principal ;
- récupérer les métadonnées ;
- construire les relations entre pages.

Les bibliothèques utilisées sont : **Requests** pour les pages statiques, **Selenium** pour les pages dynamiques, **BeautifulSoup** pour analyser le HTML, **urllib** pour gérer les URLs, et **robots.txt** pour respecter les politiques des sites.

Résultat : plus de 2 200 pages collectées automatiquement.

4.2 Module de stockage des données

Les données collectées sont stockées selon une architecture hybride :

- **MongoDB** — stockage des documents web (URL, texte, titre, domaine, label, liens, timestamp). Avantage : structure flexible.
- **Elasticsearch** — recherche rapide, indexation plein texte, filtrage. Avantage : performance élevée.
- **Neo4j** — représentation des relations entre sites, analyse de graphes, détection de communautés. Avantage : adapté aux données relationnelles complexes.

4.3 Module d'analyse de graphe

Après collecte, chaque page devient un nœud dans un graphe et chaque lien devient une arête. Un graphe de **2 102 nœuds** et **4 806 liens** a été construit, sur lequel les algorithmes suivants ont été appliqués :

- **PageRank** — détecter les sites les plus influents.
- **HITS** — distinguer les *hubs* des *authorities*.
- **Détection de communautés** — identifier des groupes de sites fortement connectés.

Les sites les plus influents détectés sont notamment : **lemonde.fr**, **cnn.com**, **bbc.com**, **google.com** et **reuters.com**. **15 communautés** ont été détectées.

4.4 Détection de fermes de liens

Une ferme de liens correspond à un groupe de sites qui se référencent artificiellement. La recherche a porté sur une densité élevée, une faible diversité et une forte interconnexion.

Résultat : aucune ferme suspecte détectée.

4.5 Analyse comportementale et Bot Score

Des logs de navigation ont été simulés afin d'analyser le nombre de requêtes, la vitesse, la régularité et la fréquence. Un **Bot Score** a été calculé sur une échelle de 0 à 1 :

- proche de 1 : comportement très suspect (bot confirmé) ;
- proche de 0 : comportement normal.

4.6 Préparation pour l'Intelligence Artificielle

Les données ont ensuite été enrichies pour permettre l'analyse IA. Les ajouts comprennent : un champ `text`, un champ `domain` et un champ `label` (fake/real). Cela permet l'entraînement supervisé et la classification automatique.

```
[NEO4J] Export des liens...
[GRAPH] 779 noeuds, 1819 liens
[METRICS] Calcul PageRank (weighted)...
[METRICS] Calcul HITS...
[MONGO] Sauvegarde des métriques...

[TOP 10 PageRank]
0.0119 - lemonde.fr
0.0112 - cnn.com
0.0098 - edition.cnn.com
0.0084 - support.google.com
0.0065 - sputnikglobe.com
0.0064 - index-en.rt.com
0.0064 - bbc.com
0.0063 - privacy.aljazeera.net
0.0063 - google.com
0.0063 - index.rt.com

[3/4] Detection des communautés suspectes...
[GRAPH] Construction du graphe avec 640 pages...
[NEO4J] Export des liens...
[GRAPH] 779 noeuds, 1819 liens
[COMMUNITY] Detection des communautés...

[COMMUNITY] 15 communautés detectees

[LINK FARMS] 0 suspectes :

[4/4] Analyse comportementale...
```

FIGURE 2 – Résultats du calcul PageRank, détection des communautés et fermes de liens

```
[BOTS] Resultats :
```

ip	nb_requests	velocity_rps	regularity_std	bot_score	is_bot
192.168.1.231	8	5.453	0.139	0.984	True
192.168.1.216	6	4.445	0.146	0.881	True
192.168.1.99	8	4.118	0.156	0.844	True
192.168.1.18	6	4.075	0.162	0.838	True
192.168.1.61	5	4.313	0.243	0.834	True
192.168.1.240	19	3.784	0.361	0.746	True
192.168.1.10	20	3.468	0.292	0.734	True
192.168.1.124	12	3.493	0.367	0.715	True
192.168.1.4	17	3.056	0.235	0.710	True
192.168.1.205	22	3.307	0.338	0.704	True
192.168.1.64	10	2.833	0.202	0.699	False
192.168.1.23	16	3.085	0.283	0.698	False
192.168.1.48	18	3.335	0.403	0.690	False
192.168.1.183	11	3.066	0.318	0.686	False
192.168.1.206	14	2.945	0.288	0.683	False
192.168.1.44	17	3.146	0.373	0.679	False
192.168.1.212	8	2.865	0.335	0.661	False
192.168.1.218	5	3.245	0.489	0.660	False
192.168.1.35	13	2.838	0.332	0.659	False
192.168.1.132	20	2.758	0.351	0.646	False
192.168.1.224	19	2.752	0.379	0.638	False
192.168.1.213	24	2.764	0.402	0.633	False

FIGURE 3 – Résultats de l'analyse comportementale — tableau des Bot Scores par IP

Résultat : plusieurs IP classées comme bots avec un score atteignant 0,984.

4.7 Prétraitement et nettoyage des données textuelles

Après la phase de collecte, une étape de prétraitement a été réalisée afin de nettoyer et normaliser les contenus récupérés. Les principales opérations effectuées sont :

- conversion des textes en minuscules ;
- suppression des caractères spéciaux ;
- suppression des liens URLs ;
- suppression de la ponctuation ;
- suppression des espaces inutiles ;
- nettoyage du contenu textuel ;
- organisation des données avec Pandas.

Les bibliothèques utilisées sont : Pandas, Regex (re), NLTK et NumPy.

Résultat : un dataset textuel nettoyé, structuré et prêt pour les analyses avancées de désinformation.

4.8 Construction du Dataset Final et Pipeline d'Exportation

Une pipeline supplémentaire a été développée afin de construire automatiquement un dataset final unifié destiné aux traitements d'IA. Cette étape joue un rôle central car elle transforme les données brutes collectées depuis MongoDB en un dataset propre.

Les objectifs du pipeline sont :

Cette étape permet de réduire fortement le bruit présent dans les données web collectées.

Les bibliothèques utilisées incluent notamment :

- Regex (re)
- NLTK
- Pandas
- unicodedata

Attribution automatique des labels

Un système d'attribution automatique des labels a été implémenté afin de catégoriser certains domaines selon leur niveau de fiabilité.

Exemple :

Sources considérées comme fiables :

- BBC
- Reuters
- Le Monde

- France24
- CNN
- DW

Sources considérées comme controversées ou suspectes :

- RT
- Sputnik

Cette étape permet de construire automatiquement un dataset supervisé destiné aux modèles de classification.

Calcul du Suspicion Score

Un score global de suspicion a été calculé pour chaque page web afin d'estimer son niveau potentiel de risque.

Ce score combine plusieurs indicateurs :

- Bot Score
- mesures du graphe
- niveau d'influence des domaines
- indicateurs comportementaux

La formule utilisée repose sur une combinaison pondérée des différents signaux détectés dans la pipeline.

Objectif :

- identifier les pages les plus suspectes
- faciliter la priorisation des analyses
- améliorer la détection automatique de désinformation

Fusion des données analytiques

Les données issues des différents modules du projet ont ensuite été fusionnées dans une structure unique :

- données web collectées
- données du graphe
- scores comportementaux
- labels
- métriques analytiques

Cette fusion permet d'obtenir une vue globale et unifiée des informations collectées.

Génération du dataset final

Une fois les traitements terminés, le pipeline exporte automatiquement les résultats vers un fichier CSV final.

Le dataset généré contient notamment :

- texte nettoyé
- domaine
- score de suspicion
- label
- informations comportementales
- métriques du graphe
- métadonnées web

```
=====
CYBERINTEL PIPELINE
=====
✅ MongoDB connecté : mongodb://localhost:27017 / cyberintel

📦 Chargement MongoDB
  2200 documents dans 'raw_pages'

🔗 Fusion

🏷️ Labels

⚡ Score

📄 Export
✅ CSV généré : datasets/clean_pages.csv
📄 1840 lignes

✅ Terminé
```

FIGURE 4 – Résultat de la pipeline CyberIntel — export du dataset `clean_pages.csv`

4.9 Pipeline d'analyse avancée par Intelligence Artificielle

Un pipeline complet d'analyse intelligente a été développé, combinant plusieurs techniques de Machine Learning, de Deep Learning et d'analyse textuelle avancée.

4.9.1 Préparation et organisation des données

Les données ont été nettoyées, structurées, équilibrées et préparées. Un système d'encodage des labels a été mis en place afin de garantir la cohérence entre les différentes phases du pipeline. Le dataset présente un fort déséquilibre entre les classes : 324 pages *real* contre 24 pages *fake*, ce qui a nécessité l'utilisation du paramètre `class_weight='balanced'` sur l'ensemble des modèles entraînés.

4.9.2 Augmentation des données

Face au faible nombre d'exemples *fake* dans le dataset original, une stratégie d'augmentation de données a été appliquée exclusivement sur la classe minoritaire :

- **Remplacement de synonymes** — générer de nouvelles variantes des textes par substitution aléatoire de mots-clés.
- **Back Translation** — traduction automatique anglais → français → anglais pour reformuler les phrases tout en conservant leur sens global.

Les données augmentées ont été intégrées uniquement dans le jeu d'entraînement afin d'éviter toute contamination du jeu de test.

4.9.3 Séparation des données et sélection des hyperparamètres

Les données ont été divisées en données d'entraînement et données de test, avec une stratégie de **split séparé par classe** : 30% des exemples *fake* et 15% des exemples *real* ont été réservés pour le test, garantissant ainsi un nombre suffisant d'exemples de la classe minoritaire dans le jeu d'évaluation. Une phase d'optimisation a été réalisée via la **validation croisée** (*Cross Validation* 5-fold) afin de tester plusieurs configurations et réduire les risques de surapprentissage.

4.9.4 Entraînement des modèles de Machine Learning

Plusieurs modèles de classification ont été entraînés :

- Logistic Regression ;
- Random Forest ;
- HistGradientBoostingClassifier.

4.9.5 Intégration du Deep Learning avec BERT

Le modèle **Sentence Transformers (BERT)** a été intégré afin d'obtenir une meilleure compréhension du contexte sémantique. Les textes ont été transformés en *embeddings* sémantiques de 384 dimensions avant la phase de classification.

4.9.6 Analyse de similarité sémantique

La **similarité cosinus** a été utilisée pour comparer les contenus suspects aux profils textuels de référence et identifier certains schémas linguistiques caractéristiques de la propagande. Deux profils de référence ont été définis : un profil *propagandiste* et un profil *neutre*.

4.9.7 Comparaison des performances

Les différents modèles ont été comparés à l'aide des métriques suivantes : Accuracy, F1-Score, ROC-AUC et matrice de confusion. Le meilleur modèle, **HistGradientBoos-**

tingClassifier, atteint une Accuracy de **95,98%**, un F1-macro de **0,8492** et un ROC-AUC de **0,9372** sur le jeu de test final composé de 24 exemples *fake* et 324 exemples *real*.




FIGURE 5 – Comparaison complète — ML Classique vs BERT

4.9.8 Analyse de polarisation (Stance Analysis)

Une étape d'analyse de polarisation a été réalisée afin d'identifier les orientations idéologiques présentes dans les textes. Trois catégories ont été définies : contenus *pro-russes*, *pro-occidentaux* ou *neutres*, basées sur un lexique de mots-clés géopolitiques.




FIGURE 6 – Analyse de Stance par domaine

4.9.9 Analyse stylométrique

Une analyse stylométrique a été réalisée afin d'étudier le style d'écriture des contenus web et d'identifier des signatures linguistiques propres aux contenus *fake*. Les caractéristiques calculées sont : longueur moyenne des mots, richesse du vocabulaire et longueur des textes.




FIGURE 7 – Analyse stylométrique — Fake vs Real

4.10 Système de Scoring Unifié et Classification des Domaines Suspects

Après les différentes phases d'analyse textuelle, comportementale et structurelle, une étape supplémentaire a été développée afin de centraliser l'ensemble des résultats analytiques dans un système unique de scoring intelligent.

L'objectif principal de cette étape est de produire un score global de suspicion permettant d'évaluer automatiquement le niveau de risque associé à chaque domaine web analysé. Ce système constitue le cœur décisionnel de la plateforme CyberIntel.

Objectif du système de scoring

Le système de scoring unifié permet de :

- fusionner plusieurs indicateurs analytiques ;
- centraliser les résultats des modèles IA ;
- attribuer automatiquement un niveau de risque ;
- détecter les domaines potentiellement liés à la désinformation ;
- prioriser les analyses de cybersécurité ;
- améliorer l'interprétation des résultats.

L'idée principale est de combiner plusieurs dimensions de détection afin d'obtenir une analyse plus robuste qu'un simple modèle de classification classique.

Sources de données utilisées

Le moteur de scoring exploite plusieurs datasets générés dans les étapes précédentes du projet :

- résultats des modèles de Machine Learning ;
- dataset `clean_pages.csv` ;
- métriques du graphe web ;

- scores comportementaux ;
- données de polarisation ;
- métriques de communautés.

Ces différentes sources sont automatiquement chargées puis fusionnées dans une pipeline unique.

Analyse des prédictions Machine Learning

Une première composante importante du score repose sur les prédictions générées par les modèles de classification.

Pour chaque page analysée, le système utilise :

- le label prédit ;
- le niveau de confiance de la prédiction ;
- les probabilités de classification.

Une méthode de moyenne pondérée par confiance a été utilisée afin de réduire l'impact des prédictions peu fiables.

Objectif :

- améliorer la robustesse du score ;
- réduire le bruit statistique ;
- gérer les contradictions entre pages d'un même domaine.

Détection des contradictions de contenu

Le système analyse également les incohérences présentes entre plusieurs pages appartenant au même domaine.

Exemple :

- certaines pages classées “fake” ;
- d'autres classées “real”.

Un taux de contradiction a été calculé afin d'identifier les domaines présentant des comportements éditoriaux incohérents.

Cette approche permet de détecter :

- des plateformes hybrides ;
- des contenus mélangés ;
- certaines stratégies de manipulation informationnelle.

Analyse des communautés web

Les métriques issues de l'analyse de graphe ont également été intégrées dans le calcul du score final.

Le système mesure notamment :

- l'isolation des communautés ;
- le niveau d'interconnexion ;
- la structure relationnelle des domaines.

Un score d'isolation communautaire a été utilisé afin d'identifier certains groupes de sites fortement connectés ou présentant des comportements anormaux.

Intégration de l'analyse de polarisation (Stance Analysis)

Les résultats de l'analyse de polarisation ont également été intégrés dans le système de scoring.

Chaque domaine reçoit un stance score basé sur :

- ses orientations idéologiques ;
- ses labels ;
- ses contenus dominants.

Les scores permettent de distinguer :

- contenus neutres ;
- contenus orientés ;
- contenus fortement polarisés.

Pondération des indicateurs

Le score final repose sur une combinaison pondérée de plusieurs indicateurs :

- score ML ;
- score communautaire ;
- score de polarisation ;
- taux de contradiction.

Chaque composante reçoit un poids spécifique afin de refléter son importance dans l'analyse globale.

Cette stratégie permet :

- une meilleure interprétation ;
- une classification plus stable ;
- une réduction des faux positifs.

Classification automatique des niveaux de risque

Après calcul du score global, chaque domaine est automatiquement classé dans une catégorie de risque :

LOW — Domaine considéré comme peu suspect.

MEDIUM — Domaine présentant certains signaux suspects.

HIGH — Domaine fortement suspect pouvant être lié à des activités de désinformation.

Cette classification facilite :

- la priorisation des analyses ;
- la visualisation des résultats ;
- l'exploitation dans le dashboard interactif.

Visualisation de la distribution des scores de suspicion

Afin d'analyser la répartition globale des domaines selon leur niveau de risque, une visualisation statistique des scores de suspicion a été générée.

Cette distribution permet :

- d'observer la concentration des scores ;
- d'identifier les domaines les plus suspects ;
- de visualiser les seuils de classification ;
- d'analyser la séparation entre les catégories LOW, MEDIUM et HIGH.

Le graphique ci-dessous présente la distribution des scores calculés par le moteur de scoring unifié.




FIGURE 8 – Distribution des scores de suspicion

4.11 Développement du Dashboard Interactif de Cyber Threat Intelligence

Dans le cadre du projet CYBERINTEL, un dashboard interactif de Cyber Threat Intelligence a été développé afin de centraliser l'ensemble des résultats produits par le pipeline de détection des domaines suspects et des contenus malveillants. L'objectif principal de cette plateforme est de fournir un environnement d'analyse visuel, interactif et orienté investigation permettant aux analystes cybersécurité d'identifier rapidement les menaces, de comprendre les comportements suspects et d'explorer les relations entre les différents domaines détectés.

Le dashboard a été conçu sous forme d'une application web interactive développée avec Streamlit. Cette technologie permet de créer des interfaces analytiques dynamiques capables d'intégrer des visualisations temps réel, des modules de Machine Learning, des graphes réseau et des systèmes de filtrage avancés dans une seule plateforme.

L'architecture du dashboard repose sur plusieurs fichiers générés automatiquement par le pipeline de traitement :

- `suspicion_scores.csv` : contient les scores de suspicion calculés pour chaque domaine ;
- `dashboard_data.csv` : regroupe les métriques stylométriques et sémantiques ;
- `predictions_finales.csv` : stocke les prédictions générées par le modèle de Machine Learning ;
- `comparaison_modeles.csv` : contient les performances comparatives des différents modèles ;
- `graph_links.json` : représente les relations détectées entre les domaines.

Ces fichiers sont chargés dynamiquement grâce au mécanisme `st.cache_data`, permettant d'optimiser les performances du dashboard et de réduire les temps de chargement. L'interface adopte un design de type *dark cyber theme*, inspiré des centres SOC (*Security Operations Center*). Elle utilise une palette de couleurs orientée cybersécurité :

- rouge : menace critique (HIGH) ;
- orange : menace modérée (MEDIUM) ;
- vert : faible menace (LOW).

Le dashboard est structuré autour de plusieurs modules accessibles via une barre de navigation dynamique :

- Overview ;
- Domains ;

- ML Engine ;
- Network ;
- Pipeline.

Chaque module correspond à une étape spécifique de l'analyse des cybermenaces.

4.11.1 1. Page Overview — Vue Globale des Menaces

La page **Overview** constitue le tableau de bord principal du système. Elle fournit une vue synthétique des menaces détectées ainsi que des principaux indicateurs statistiques du pipeline.

Cette section affiche plusieurs KPI importants :

- le nombre total de domaines analysés ;
- le nombre de domaines HIGH risk ;
- le score moyen de suspicion ;
- le nombre total de prédictions générées.

Les domaines sont classifiés selon trois niveaux de risque :

- HIGH : $\text{score} \geq 0.62$;
- MEDIUM : $0.45 \leq \text{score} < 0.62$;
- LOW : $\text{score} < 0.45$.




FIGURE 9 – Dashboard Overview — KPI globaux

Histogramme de Distribution des Scores

Un histogramme interactif représente la distribution des scores de suspicion calculés pour les domaines analysés.

Chaque barre du graphique correspond au nombre de domaines appartenant à un intervalle de scores donné. Les couleurs permettent de distinguer les niveaux de risque :

- rouge : domaines HIGH ;
- orange : domaines MEDIUM ;
- vert : domaines LOW.

Deux lignes verticales indiquent les seuils critiques utilisés par le système :

- seuil MEDIUM : 0.45 ;
- seuil HIGH : 0.62.

Cette visualisation permet :

- d'analyser la répartition globale des menaces ;
- d'identifier les zones critiques ;
- d'évaluer la densité des domaines suspects.

Le graphique supporte également le zoom interactif, les interactions souris et l'affichage dynamique des valeurs.

Diagramme Circulaire de Répartition des Risques

La page Overview contient également un diagramme circulaire de type *donut chart* représentant la répartition des domaines selon les niveaux de risque :

- HIGH ;
- MEDIUM ;
- LOW.

Cette visualisation facilite l'évaluation rapide du niveau global de menace détecté par le système.

Graphique des Domaines les Plus Suspects

Le dashboard affiche un graphique en barres horizontales représentant les domaines ayant obtenu les scores de suspicion les plus élevés.

Pour chaque domaine, le système affiche :

- le score exact de suspicion ;
- le niveau de risque ;
- le classement parmi les domaines suspects.

Cette visualisation permet de prioriser les investigations et d'identifier rapidement les domaines critiques.



FIGURE 10 – Top domaines les plus suspects

4.11.2 2. Page Domains — Analyse détaillée des domaines

La page **Domains** fournit une analyse approfondie des domaines suspects détectés par le système.

Cette section contient :

- les scores de suspicion ;
- les probabilités du modèle ML ;
- les taux de contradiction ;
- les scores sémantiques ;
- les métriques communautaires.




FIGURE 11 – Page Domains — vue globale

Gauge de Niveau de Menace

Le dashboard intègre un graphique de type *Gauge Chart* permettant de visualiser le score maximal de suspicion parmi les domaines filtrés.

La jauge est divisée en plusieurs zones :

- vert : faible risque ;
- orange : risque modéré ;
- rouge : menace critique.

Cette représentation facilite la compréhension immédiate du niveau de danger actuel du système et permet d'identifier rapidement si le score global dépasse le seuil critique défini par les modèles d'analyse.

Décomposition des Contributions au Score

Un graphique en barres empilées représente les différentes contributions intervenant dans le calcul du score final de suspicion.

Le score est composé de plusieurs éléments :

- contribution du modèle ML ;
- contribution de la stance analysis ;
- contribution du taux de contradiction ;
- contribution de l'isolement communautaire.




FIGURE 12 – Histogramme de Distribution des Scores

Chaque couleur représente une composante spécifique du score.

Cette visualisation améliore fortement l'interprétabilité du système en expliquant précisément l'origine du score attribué à chaque domaine.

Elle permet également d'identifier les facteurs dominants responsables du niveau de suspicion.

Tableau Interactif des Domaines

Le dashboard contient un tableau interactif affichant les principales métriques associées à chaque domaine :

- score de suspicion ;
- niveau de risque ;
- probabilité fake ;
- contradiction rate ;
- stance score ;
- community isolation.

Le tableau supporte :

- le tri dynamique ;
- le filtrage ;
- l'export CSV ;
- l'export JSON.

Les niveaux de risque sont automatiquement colorés afin d'améliorer la lisibilité visuelle et de faciliter le travail des analystes SOC lors des investigations.

TABLEAU DES DOMAINES FILTRÉS

SCORES - 348 DOMAINES FILTRÉS

	domain	suspicion_score	risk_level	ml_fake_proba	contradiction_rate	stance_score	community_iso
125	fr.gw2ru.com	0.6611	HIGH	0.9292	0.0000	1.0000	0.0000
196	mondoblog.org	0.6474	HIGH	0.9043	0.0000	1.0000	0.0000
126	francais.rt.com	0.5413	MEDIUM	0.7115	0.0000	1.0000	0.0000
128	francem.com	0.5282	MEDIUM	0.7344	0.4000	0.4286	0.0000
198	mpublicite.fr	0.4832	MEDIUM	0.6058	0.5000	0.5000	0.0000
148	gymglish.com	0.4662	MEDIUM	0.5749	0.5000	0.5000	0.0000
219	oneplanetsummit.fr	0.4400	LOW	0.8959	0.0000	1.0000	0.0000
168	kiosque.lavie.fr	0.4400	LOW	0.8813	0.0000	1.0000	0.0000
39	arcade.lemonde.fr	0.4400	LOW	0.9422	0.0000	1.0000	0.0000
42	ateliers.lemonde.fr	0.4400	LOW	0.5418	0.5000	0.5000	0.0000
33	anchor.fm	0.4400	LOW	0.9043	0.0000	1.0000	0.0000
181	linc.cnil.fr	0.4400	LOW	0.9054	0.0000	1.0000	0.0000

↓ Exporter CSV ↓ Exporter JSON

FIGURE 13 – Tableau interactif des domaines filtrés

4.11.3 3. Page ML Engine — Analyse du modèle

La page **ML Engine** est dédiée à l'analyse des performances des modèles de Machine Learning utilisés dans le pipeline.

Elle permet d'évaluer :

- la qualité des prédictions ;
- la précision des modèles ;
- la distribution des classes ;
- les niveaux de confiance des prédictions.




FIGURE 14 – Dashboard ML Engine

Comparaison des Modèles

Le dashboard affiche un graphique en barres groupées permettant de comparer plusieurs modèles de classification selon différentes métriques :

- Accuracy ;
- F1-score fake ;
- F1-score real ;
- F1-macro ;
- ROC-AUC.

Cette visualisation permet d'identifier le meilleur modèle et d'évaluer la robustesse des différents algorithmes de classification.

Histogramme des Confiances ML

Un histogramme interactif représente la distribution des probabilités de confiance des prédictions générées par le modèle.

Le graphique compare :

- les prédictions fake ;
- les prédictions real.

Une ligne verticale indique le seuil utilisé dans l'apprentissage semi-supervisé.

Cette analyse permet :

- d'évaluer la calibration du modèle ;
- d'identifier les prédictions ambiguës ;
- d'améliorer la robustesse du moteur ML.

Matrice de Confusion

Une matrice de confusion a été intégrée afin d'évaluer les performances du système de classification.

Elle compare :


- les prédictions réalisées ;
- les labels réels.

Cette représentation permet d'identifier :

- les vrais positifs ;

- les faux positifs ;
- les faux négatifs ;
- les vrais négatifs.

La matrice constitue un indicateur essentiel pour analyser les erreurs du modèle et améliorer ses performances.



4.11.4 4. Page Network — Analyse des relations

La page **Network** constitue le module d'analyse relationnelle du système.

Le graphe du réseau est construit à l'aide de la bibliothèque **NetworkX**, à partir des relations contenues dans le fichier `graph_links.json`.




FIGURE 15 – Graphe réseau global

Graphe Réseau Interactif

Dans ce graphe :

- chaque nœud représente un domaine ;
- chaque arête représente une relation entre deux domaines.

Les propriétés visuelles du graphe sont les suivantes :

- la taille du nœud est proportionnelle au score de suspicion ;
- la couleur du nœud représente le niveau de risque ;
- les liens représentent les connexions détectées entre domaines.

Cette représentation permet :

- de détecter des clusters suspects ;
- d'identifier des campagnes coordonnées ;
- d'analyser les relations entre domaines malveillants ;
- d'identifier les hubs centraux du réseau.




FIGURE 16 – Carte des relations entre domaines

Détection des Communautés

Le dashboard applique l'algorithme *Greedy Modularity Communities* afin de détecter automatiquement les communautés dans le réseau.

Chaque communauté peut représenter :

- une campagne de phishing ;

- un botnet ;
- une infrastructure C2 ;
- un réseau coordonné de désinformation.

Le dashboard affiche :

- le nombre de membres ;
- le score moyen du cluster ;
- le nombre de menaces critiques ;
- les domaines principaux.

Cette analyse permet d’orienter les investigations vers les groupes les plus dangereux et d’identifier les structures malveillantes organisées.

COMMUNAUTÉS DÉTECTÉES (GRAPH_LINKS.JSON)

	Cluster	Membres	Score moyen	Menaces HIGH	Domaines clés
0	#1	4	0.327	0	la-beaute-creatrice.lemonde.fr, langues.lemonde.fr, lavie.fr, learn.microsoft.com
1	#2	4	0.560	2	fr.gw2ru.com, fr.sputniknews.africa, francais.rt.com, francaisfacile.rfi.fr
2	#3	3	0.210	0	abo.lavie.fr, abo.lemonde.fr, abos.telerama.fr
3	#4	2	0.559	1	monde-diplomatique.fr, mondoblog.org
4	#5	2	0.440	0	boutique.lavie.fr, boutique.lemonde.fr
5	#6	2	0.228	0	francemediasmonde.com, francemm.com
6	#7	2	0.156	0	myactivity.google.com, myadcenter.google.com
7	#8	2	0.322	0	kiosque.lavie.fr, kr3m.com

CYBERINTEL Threat Intelligence Platform v3.1

FIGURE 17 – Communautés détectées

4.11.5 5. Page Pipeline — Vue globale du pipeline CTI

La page **Pipeline** offre une vue d’ensemble complète du pipeline de Cyber Threat Intelligence développé dans le projet CYBERINTEL.

Elle centralise les différentes étapes du traitement des données, depuis l’extraction des contenus jusqu’à la génération des scores de suspicion et des analyses réseau.

Cette page permet de visualiser :

- les données analysées ;
- les prédictions générées ;
- les scores de suspicion calculés ;
- les performances des modèles ;
- les métriques stylométriques et sémantiques.




FIGURE 18 – Vue globale du pipeline CYBERINTEL

Indicateurs Globaux du Pipeline

Le dashboard affiche plusieurs indicateurs clés permettant de suivre l'état global du pipeline :

- le nombre de pages analysées ;
- le nombre de prédictions générées ;
- le nombre de domaines scorés ;
- le nombre de modèles comparés.

Ces indicateurs sont calculés à partir des fichiers :

- `dashboard_data.csv` ;
- `predictions_finales.csv` ;
- `suspicion_scores.csv` ;
- `comparaison_modeles.csv`.

Ils permettent d'obtenir une vision synthétique de l'activité du système de détection.

Analyse Stylométrique

Le dashboard intègre une analyse stylométrique permettant de comparer les caractéristiques linguistiques des contenus *fake* et *real*.

Les métriques analysées sont :

- la longueur moyenne des mots ;

- la richesse du vocabulaire ;
- la longueur moyenne des textes.

Les résultats sont affichés sous forme de graphiques interactifs permettant de comparer les comportements linguistiques des différentes classes. Cette analyse permet :

- d’identifier les différences stylistiques ;
- de détecter des patterns rédactionnels suspects ;
- d’améliorer les performances du modèle de classification.

5. Conclusion Générale

Ce projet nous a permis de concevoir et développer une plateforme intelligente de Cyber Threat Intelligence dédiée à la détection de désinformation web à travers des techniques de Web Mining, d’analyse de graphes et d’Intelligence Artificielle.

L’objectif principal était d’analyser automatiquement les contenus web, détecter les comportements suspects et identifier les domaines potentiellement liés à des campagnes de désinformation. Pour cela, plusieurs modules ont été développés, notamment la collecte des données web, le stockage dans différentes bases de données, l’analyse des relations entre sites, l’analyse comportementale, ainsi que l’utilisation de modèles de Machine Learning et de Deep Learning.

Le projet a également permis de mettre en place un système de scoring unifié capable de combiner plusieurs indicateurs analytiques afin d’évaluer le niveau de risque des domaines web analysés. Les résultats obtenus ont ensuite été visualisés dans un dashboard interactif inspiré des environnements SOC de cybersécurité.

Ce travail nous a permis d’acquérir des compétences importantes en Data Science, cybersécurité, intelligence artificielle, analyse de graphes et développement de pipelines analytiques.

Enfin, malgré certaines limites liées aux données et aux ressources de calcul, ce projet constitue une base solide pour le développement futur de solutions avancées de détection de désinformation et de Cyber Threat Intelligence.